

Aprendizaje Automático

Trabajo Práctico

Departamento de Computación
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Segundo cuatrimestre 2026

Introducción

En el mundo actual, distintas disciplinas científicas empiezan, cada vez más, a interactuar con el fin de potenciar sus descubrimientos. En este caso dos grupos de investigación de CONICET se embarcan en la combinación entre biología y informática para abordar la detección temprana y el pronóstico preciso de enfermedades como el cáncer. Este proyecto combina las tecnologías de secuenciación de nueva generación (*NGS*, por sus siglas en inglés) con la potencia de la inteligencia artificial. El enfoque se centra en un dataset único que abarca mediciones de *ARN* de 200 *genes*, recopiladas de pacientes con lesiones *pre-tumorales*. Este conjunto de datos se convierte en una valiosa fuente de información para entender cómo las células en estado de hiperplasia pueden evolucionar hacia *tumores malignos*, una transformación que ha desconcertado a la ciencia durante décadas.

La hiperplasia, es un fenómeno en el que las células experimentan un crecimiento anormal y descontrolado, es un punto de partida crucial en nuestro análisis. ¿Cómo y por qué algunas células que experimentan hiperplasia se convierten en células cancerosas, mientras que otras no? Esta pregunta es el corazón de nuestra investigación. Para responderla se realizó un estudio donde se obtuvieron muestras de distintos tipos de hiperplasias de pacientes con antecedentes familiares y lesiones pre tumorales. Este grupo de pacientes, o cohorte, fue monitoreado periódicamente durante los siguientes 5 años buscando indicios de neoplasias o nuevas hiperplasias más agresivas. Con las muestras obtenidas en este estudio se realizó un *biobanco* con las mediciones que habitualmente se hacen en la construcción de este tipo de *plataformas*. Cada muestra fue etiquetada como **buen pronóstico**, si no hubo indicios de nuevas hiperplasias o similares; contrariamente se etiquetaron como de **mal pronóstico** si hubo una recaída.

Clasificación binaria de lesiones pre-tumorales

En concreto, se dispone de un archivo `.csv` accesible en este *link* que contiene:

- Una matriz de datos X de 500 filas, donde cada fila $x^{(i)}$ representa un vector de 200 características de una instancia: $\mathbf{x}^{(i)} = (x_1^{(i)}, \dots, x_{200}^{(i)})$, con $1 \leq i \leq 500$.
- Una columna **target** que representa un vector de 500 posiciones con dos valores posibles: **True** (o 1, buen pronóstico) y **False** (o 0, mal pronóstico).

Condiciones de aprobación

Utilizando estos datos, deberán completar las consignas listadas en este documento y redactar un informe de trabajo en formato PDF el cual contenga la resolución de todas las consignas, acompañado de un texto que explique, reflexione, justifique y concluya sobre dicho contenido. Cada gráfico incluido debe contar con:

- Nombres de los ejes.
- Título.
- Leyenda autocontenida.
- Referencia desde el texto, ya que su inclusión se da porque aporta a la discusión del trabajo.

El informe no puede superar un máximo de 8 carillas (contando gráficos) o 4 hojas más carátula. No se corregirán trabajos que no cumplan con estos lineamientos.

Además de este informe, deberán presentar también un notebook que contenga el código implementado para resolver las consignas y generar los gráficos/tablas/resultados reportados en el informe.

Habrán 2 entregas: una entrega intermedia y una entrega final. Para la entrega intermedia deberán enviar el código que resuelve los primeros tres ejercicios. La fecha límite es el **martes 15 de Septiembre**. La entrega final, con fecha límite el **jueves 24 de Septiembre**, deberá incluir:

- Informe final en formato PDF.
- El notebook final en formatos `.pdf` y `.ipynb`. Los resultados deben poder reproducirse al ejecutar todas las celdas en orden.
- Las predicciones del conjunto de *control* del Ejercicio 4 en formato CSV.

La evaluación será grupal y considerará la calidad del informe –presentación, claridad y prolijidad–, así como la originalidad, practicidad y coherencia técnica de la solución, y la corrección y solidez de las pruebas realizadas. Se podrán solicitar pruebas de integridad y autoría para verificar que la salida solicitada proviene del modelo presentado y que fue construido según lo requerido.

Consignas

A continuación se presentan las consignas que deberán resolverse como parte del trabajo práctico. Recomendamos fuertemente que primero repasen todas las consignas, para luego comenzar con la resolución en el orden en que aparecen.

1. Separación de datos

Se cuenta con una cantidad limitada de datos, por lo que es importante tomar una buena decisión al comenzar a utilizarlos.

1.1. Evaluar y definir una manera de separar los datos para desarrollo y evaluación.

1.2. ¿Qué consideraciones tuvieron en cuenta para realizar esta división? Justificar.

Importante: en este punto no está permitido dividir la base de datos utilizando la función `train_test_split` de *sklearn*. Deben decidir e implementar la separación.

2. Construcción de modelos

Buscamos construir y evaluar modelos de **árboles de decisión**, obteniendo una **estimación realista de su performance**.

2.1. Entrenar un árbol de decisión con altura máxima 3 y el resto de los hiperparámetros en sus valores por defecto.

2.2. Estimar la performance del modelo utilizando validación cruzada *K-fold* con $K = 5$ y las métricas *Accuracy*, *Area Under the Precision-Recall Curve* (AUPRC) y *Area Under the Receiver Operating Characteristic Curve* (AUCROC). Además de calcular las métricas de cada *fold* y su promedio, calcular el *score* global –como se vio en clase– utilizando únicamente los *folds* de validación. Reporten los resultados en una tabla como la siguiente:

Permutación	Accuracy (train)	Accuracy (validation)	AUPRC (train)	AUPRC (validation)	AUCROC (train)	AUCROC (validation)
1						
2						
3						
4						
5						
Promedios						
Global	(NO)		(NO)		(NO)	

Importante: de aquí en adelante, al usar validación cruzada *K-fold*, utilicen solamente el *score* promedio.

2.3. Explorar las siguientes combinaciones de parámetros para árboles de decisión, manteniendo validación cruzada con $K = 5$ y utilizando `ParameterGrid` de *scikit-learn*. No está permitido usar `GridSearchCV` en este ejercicio.

Altura máxima	Criterio de corte	Accuracy (training)	Accuracy (validación)
3	Gini		
5	Gini		
Infinito	Gini		
3	Entropía		
5	Entropía		
Infinito	Entropía		

2.4. ¿Qué conclusiones pueden extraer de estas tablas?

3. Comparación de algoritmos

Vamos a explorar distintas combinaciones de algoritmos de aprendizaje y configuraciones con el objetivo de encontrar el mejor modelo de cada familia y buscar la performance óptima. Realizar la experimentación con `RandomizedSearchCV`. Como métrica de performance, utilizar AUCROC obtenida mediante validación cruzada de 5 *folds*. Revisar la documentación de cada hiperparámetro para identificar cuáles podrían impactar positivamente en la construcción de cada algoritmo. Como documentación complementaria, consultar *Tuning hyper-parameters* hasta la sección 3.2.2.

3.1. Probar los siguientes algoritmos:

- Árboles de decisión: mínimo 4 hiperparámetros.
- KNN (*k-nearest neighbors*): mínimo 3 hiperparámetros.
- SVM (*support vector machine*): mínimo 2 hiperparámetros.

Detallar los hiperparámetros elegidos para cada algoritmo y explicar la razón del espacio de búsqueda considerado. Indicar cuántas iteraciones utilizaron y reportar la performance de las combinaciones relevantes, incluyendo como mínimo la mejor combinación de cada algoritmo.

3.2. Comparar los resultados anteriores con los siguientes modelos, usando sus hiperparámetros por defecto:

- LDA (*Linear Discriminant Analysis*).
- Naïve Bayes.

Responder: ¿Qué resultados se obtienen? ¿Qué hiperparámetros podrían ser relevantes de explorar en estos modelos y por qué?

3.3. ¿Cuál fue el mejor modelo y con qué configuración? Explicar por qué creen que obtuvo mejor desempeño, considerando qué hace cada algoritmo y el tipo de datos con el que están trabajando.

4. Evaluación de performance

Vamos a realizar una evaluación para poner a prueba el mejor modelo y ver si efectivamente somos capaces de estimar su desempeño real. Los datos se encuentran en este [link](#). Las decisiones de este punto pueden desarrollarse en hasta una carilla, aunque media carilla debería ser suficiente.

4.1. Estimar el valor de AUCROC que tendrá su mejor modelo sobre los datos de control `X_control`

4.2. Predigan las **probabilidades de la clase positiva** para las distintas instancias con el modelo. Envíen dichas probabilidades junto con una estimación, con 4 decimales, del AUCROC resultante. Se calculará el valor real luego de la entrega y se considerará mejor modelo al que se encuentre más cerca de dicho valor.

4.3. Adjuntar al informe final un archivo .CSV cuyo nombre incluya el número de grupo con dos dígitos, las predicciones y el valor AUCROC estimado con cuatro decimales, siguiendo el formato `GG_y_pred_control_AUCROC`. Por ejemplo, si el grupo 3 estima un AUCROC

de 0.7321, deberá adjuntar `03_y_pred_control_7321.csv`. El archivo deberá contener una columna llamada `output`

5. Conclusiones

5.1. Escriban una conclusión de al menos un párrafo sobre el trabajo realizado, incluyendo los problemas encontrados y aspectos no incluidos en el enunciado que hayan abordado durante el desarrollo.

Importante: uso de ChatGPT y grandes modelos de lenguaje

El uso de ChatGPT y otros grandes modelos de lenguaje no está explícitamente prohibido, pero se desaconseja fuertemente, ya que este trabajo práctico es una herramienta de aprendizaje y su uso puede ser perjudicial. En caso de utilizarlo, deberán aclararlo en el informe, especificar cómo y dónde se empleó, y expresar su opinión sobre la respuesta generada por el modelo, ya sea a favor o en contra. Pueden adjuntar el enlace a la conversación con el modelo.

Nota. Se agradece a Martín García Sola por la asistencia biológica en la confección de este trabajo práctico.